Tastoria — Báo cáo module Xử lý ảnh và Thị giác máy tính

Oct 22, 2026 · @CTS Lab

1. Tóm tắt

Module thị giác máy tính của Tastoria biến 1–2 ảnh tủ lạnh thành danh sách nguyên liệu có số lượng và mức độ tươi. Hiện module đã chạy thật trên `safework.ctslab.net`: bộ phát hiện YOLO26n (ONNX, CPU) cho xử lý phía server p95 = 105 ms. Tuy vậy, mọi số đo chất lượng mới có trên **ảnh công khai**, chưa có ảnh tủ lạnh nào của người Việt.

Kết quả chính (tập test công khai, 3 seed):

- **Phát hiện 13 lớp:** AP@[.5:.95] COCO = 0,268 ± 0,005, AP50 = 0,414. Vật nhỏ chỉ đạt AP = 0,03.
- **Tiền xử lý:** gray-world và tăng cường đổi nguồn sáng hơn ảnh gốc khoảng 0,7 điểm mAP50-95, nằm trong biên tương đương ±1,5 điểm. Chưa kết luận được là có lợi.
- **Đếm:** sai số tuyệt đối trung bình (MAE) 1,67 vật trên mỗi cặp (ảnh, lớp). Mức này chỉ tốt hơn baseline "trung vị theo lớp" (1,80) một chút.
- **Độ tươi:** MobileNetV3-Small đạt macro-F1 0,828 so với 0,766 của SVM đặc trưng cổ điển, sau khi đã gộp ảnh cận trùng.

Ba vấn đề lớn còn mở:

1. Không có dữ liệu tủ lạnh thật. 9/22 lớp (thịt, đậu phụ, rau lá Việt…) không có ảnh huấn luyện nào.
2. Đếm vật xếp chồng và vật nhỏ yếu.
3. Nhãn độ tươi mượn từ bộ dữ liệu khác định nghĩa, không phải nhãn thị giác do người chấm.

2. Vị trí module trong hệ thống

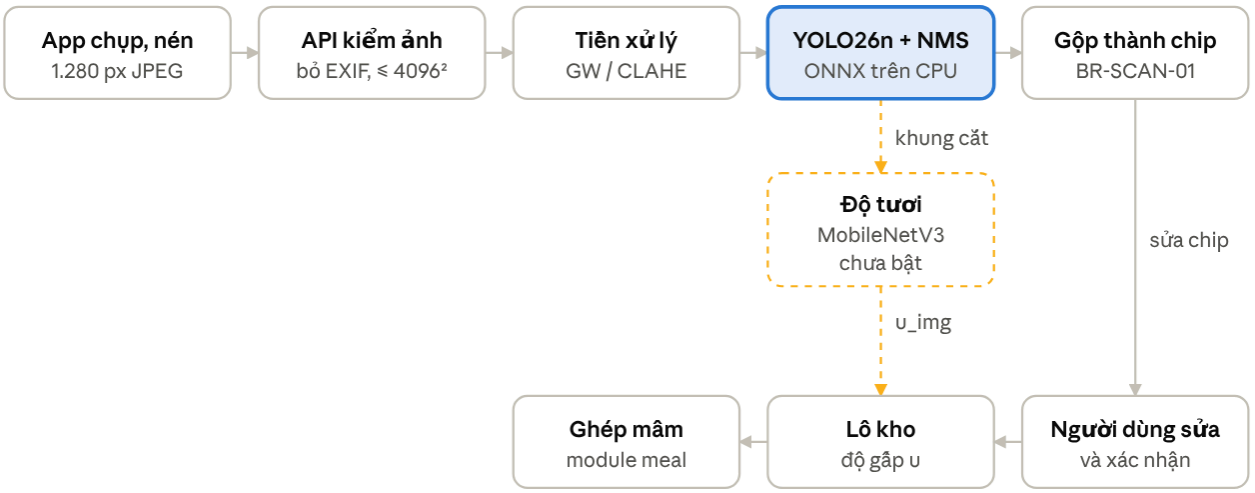
Module là cửa vào dữ liệu của cả Tastoria: kho nguyên liệu, độ gấp và bộ ghép mâm đều dùng đầu ra của nó. Người dùng luôn sửa được kết quả trước khi nó vào kho, nên sai số của mô hình làm tốn công sửa chứ không tự động sinh ra mâm sai.

Luồng xử lý một lần quét (UC12, UC13):

1. App nén ảnh về cạnh dài 1.280 px, gửi `POST /api/v1/scans`. Server kiểm magic bytes, giới hạn 4096^2 điểm ảnh, xoay theo EXIF rồi mã hoá lại JPEG không metadata.

2. Worker RQ (nạp ONNX một lần, 2 luồng CPU) chạy tiền xử lý, YOLO26n, NMS theo lớp, ánh xạ lớp thị giác sang nguyên liệu.
3. Gộp khung thành chip theo BR-SCAN-01: cùng ngăn lấy max số đếm giữa các ảnh, khác ngăn thì cộng.
4. App long-poll `GET /scans/{id}?wait=10`, người dùng sửa chip, bấm xác nhận. Bước xác nhận ghi lô kho trong một giao dịch, gửi lại không tạo trùng.
5. Độ gấp của lô tính lúc đọc từ số ngày và (khi có) xác suất độ tươi từ ảnh (BR-FRESH-01..05).

Ảnh qua năm bước trước khi thành lô kho; nhánh độ tươi chưa bật



luồng một lần quét · 5 bước tự động, 1 bước người dùng

Bộ phát hiện là bước duy nhất có mô hình đang chạy trên bản live; nhánh độ tươi (nét đứt) đã có mô hình ONNX nhưng chưa bật, nên độ gấp hiện chỉ tính theo số ngày.

Mã	Yêu cầu	Trạng thái
NFR-PERF-01	Xử lý quét phía server p95 ≤ 3 s	Đạt: p95 = 105 ms (1 người), 178 ms (5 người, 300 lượt), đo qua URL công khai
BR-SCAN-01	Gộp nhiều ảnh: cùng ngăn lấy max, khác ngăn cộng	Đã cài, có kiểm thử
BR-SCAN-02	Chỉ xác nhận mới ghi kho, lũy đẳng	Đã cài, có kiểm thử 4 lần xác nhận đồng thời
BR-FRESH-02	u_img từ xác suất 4 mức độ tươi	Chưa bật trên live: mô hình độ tươi mới có 3 mức, chưa hiệu chỉnh

Mã	Yêu cầu	Trạng thái
Bảo mật ảnh	Xoá ảnh gốc sau 30 ngày trừ khi đồng ý góp ảnh	Đã cài (job hằng giờ)

3. Các bài toán cần giải quyết

Module gồm sáu bài toán. Bài 2, 3, 4 là lõi chấm điểm của môn Xử lý ảnh; bài 1, 5, 6 giúp chúng chạy đúng trong điều kiện thật.

Bài toán 1 — Chuẩn hoá ánh sáng. Đèn LED tủ lạnh (khoảng 6.500 K) và đèn phòng (khoảng 2.700 K) làm cùng một màu rau trông khác nhau. Trong mô hình von Kries, ảnh quan sát là phản xạ nhân theo từng kênh với nguồn sáng e:

```
c_k(x) = e_k \, \rho_k(x), \quad k \in \{R, G, B\}
```

Cần ước lượng e từ chính ảnh rồi chia ra. Song song cần cân bằng độ tương phản giữa ngăn sáng và ngăn tối mà không đổi sắc độ. Câu hỏi nghiên cứu: bước này có làm tăng AP của bộ phát hiện hay F1 của bộ phân loại độ tươi không?

Bài toán 2 — Phát hiện nguyên liệu. Cho ảnh I, tìm tập khung và lớp:

```
f(I) = \{(b_i, y_i, s_i)\}_{i=1}^{n}, \quad b_i \in [0,1]^4,\; y_i \in \{1, \dots, K\},\; s_i \in [0,1]
```

với K = 22 lớp trong `vision_classes.yaml`. Điều kiện khó: vật che nhau, bọc túi nilon, vật nhỏ (ớt, tỏi, chanh chỉ vài chục pixel ở 640 px), và lớp giống nhau (cải ngọt/cải chíp, rau muống/rau lang). Mô hình phải chạy trên VPS 2 vCPU.

Bài toán 3 — Đếm. Với lớp đếm được, số trên chip là ĉ = số khung có điểm ⩾ τ. Cần chọn τ và ngưỡng NMS sao cho ĉ gần số vật thật c. Phải phân biệt số vật *nhìn thấy* với số vật *có trong tủ*, và tránh đếm một quả hai lần khi chụp hai góc.

Bài toán 4 — Phân loại độ tươi. Cho ảnh cắt của một vật, ước lượng mức có thứ bậc tươi < dùng sớm < dùng ngay (< kiểm tra) dưới dạng phân phối xác suất đã hiệu chỉnh, để đưa vào độ gấp:

```
u_{img} = \sum_{c} P(c \mid x)\, m(c), \quad m = (0{,}25;\ 0{,}65;\ 0{,}9;\ 1{,}2)
```

Vì nhãn có thứ tự, nhầm "tươi" thành "dùng ngay" phải bị phạt nặng hơn nhầm sang mức kề.

Bài toán 5 — Thu và gán nhãn dữ liệu đáng tin. Cần tập test đại diện cho tủ lạnh Việt và đo được độ tin cậy nhãn, vì mọi con số ở bài 2–4 chỉ có ý nghĩa khi nhãn đáng tin.

Bài toán 6 — So với mô hình đa phương thức. Gemini đã trả được khung `box_2d`. Câu hỏi then chốt của đề tài: một mô hình nano tự huấn luyện có đáng giữ so với gọi API không, xét độ chính xác, độ trễ, chi phí và quyền riêng tư?

4. Dữ liệu

Toàn bộ dữ liệu hiện có là ảnh công khai giấy phép CC BY. Chưa có ảnh nào chụp trong tủ lạnh Việt, nên mọi kết quả ở mục 6 chỉ so sánh phương pháp, không dự báo được độ chính xác khi dùng thật.

Bộ dữ liệu	Giấy phép	Dùng cho	Quy mô sau lọc
Open Images V7, tập boxable	Nhãn CC BY 4.0, ảnh CC BY 2.0	Phát hiện, 11 nhãn	10.873 ảnh
Vegetable Object Detection Dataset, Bangladesh (Jahan và cộng sự 2025)	CC BY 4.0	Phát hiện, 9 nhãn	3.150 khung hình từ 10 video
AgriFreshNET (Risdin và cộng sự 2026)	CC BY 4.0	Độ tươi, 3 mức	5.183 ảnh
Local Spinach Leaf (Hasan và cộng sự 2024)	CC BY 4.0	Độ tươi rau lá, có rau muống	3.999 ảnh

Tập phát hiện sau khi gộp: train 11.091, val 897, test 2.035 ảnh; test có 7.946 khung thật. Bangladesh được chia theo video, không theo khung, vì các khung của cùng một video gần giống hệt nhau. Ảnh cận trùng bị loại bằng pHash 64 bit (Hamming ⩽ 4).

Khoảng trống lớp. 13/22 lớp có ảnh công khai: cá, tôm, trứng, cà chua, cà rốt, khoai tây, bắp cải, súp lơ, bí đỏ, bí đao/bầu, mướp đắng, đậu que, nấm. 9 lớp không có ảnh nào: thịt lợn, thịt bò, thịt gà, đậu phụ, su su, mướp, rau cải, rau muống, giá đỗ. Chính những lớp này là nguyên liệu chính của mâm cơm Việt. Việc chọn 22 lớp theo ba tiêu chí (nguyên liệu chính, để ngăn mát, tách được bằng mắt) nằm trong `data/kb/vision_classes.yaml`. Một số bộ cộng đồng trên Roboflow có ba chỉ, giá đỗ, cải ngọt, nhưng cần khoá API và chưa kiểm được nguồn gốc ảnh.

Nhãn độ tươi mượn. 9.182 ảnh độ tươi mang nhãn của tác giả bộ dữ liệu: AgriFreshNET theo hạn dùng, Local Spinach theo "fresh / non-fresh". Nhãn được ánh xạ về tươi 3.809 / dùng sớm 1.643 / dùng ngay 3.730. Đây không phải nhãn thị giác 4 mức do hai người chấm mù ngày chụp như thiết kế v2 yêu cầu.

Dữ liệu nhóm phải tự thu (thiết kế v2, mục 5–7):

- Ảnh tủ lạnh của ≥ 12–15 hộ, 2–3 phiên mỗi hộ, kèm metadata hộ / phiên / ngăn / đèn / đời máy. Để ≥ 4 hộ làm tập test, mỗi lớp ≥ 30–50 vật thể trong test.
- Lô độ tươi: 6–8 loại rau lá và cà chua, ≥ 6–8 lô mỗi loại, mua ở ≥ 3 nơi. Chụp kiểu quét 2 lần mỗi ngày với thẻ xám 18% ở góc ảnh.
- Vòng gán nhãn thử 100–150 ảnh do hai người gán từ đầu, trước khi đóng băng tập test.

5. Phương pháp và hướng giải quyết

Mỗi bài toán dùng phương pháp đã được kiểm chứng trong tài liệu. Đóng góp riêng của nhóm nằm ở dữ liệu nguyên liệu Việt, cách đánh giá và việc ghép các bước vào hệ thống chạy thật. Mã nằm ở `ml/src/tastoria_ml/cv/`.

5.1 Cân bằng trắng và CLAHE (bài toán 1)

Ảnh 8 bit được giải mã sRGB về RGB tuyến tính trước khi ước lượng nguồn sáng. Nguồn sáng là trung bình Minkowski bậc p trên các điểm không cháy sáng (kênh < 250) và không gần đen:

```
e_k = \Big( \frac{1}{|\Omega|} \sum_{x \in \Omega} c_k(x)^p \Big)^{1/p},
\qquad c'_k = \frac{\bar{e}}{e_k}\, c_k
```

- Gray-world (Buchsbaum 1980) là p = 1; shades-of-gray (Finlayson & Trezzi 2004) là p = 6.
- Hệ số kẹp trong [1/2; 2], để một khung toàn rau xanh không bị đẩy sang tím — đây là điểm yếu đã biết của giả thuyết thế giới xám.
- CLAHE (Zuiderveld 1994) chỉ chạy trên kênh L* của CIE L*a*b*, nên sắc độ giữ nguyên. Tham số được chọn trên val: clip 1,0, lưới 16×16, trong 5 cấu hình × 20 epoch.
- Nhánh thay thế "tăng cường đổi nguồn sáng" (theo Afifi & Brown 2019): không sửa ảnh lúc suy luận, mà nhân ngẫu nhiên tỉ lệ R/B trong khoảng 2^±1,2 khi huấn luyện.
- Mọi phép áp lên toàn ảnh, giống nhau cho train/val/test, không bao giờ áp riêng trên khung cắt.

5.2 Phát hiện bằng YOLO26n (bài toán 2)

YOLO (Redmon và cộng sự 2016) dự đoán khung và lớp cho toàn ảnh trong một lượt truyền: 8.400 vị trí ở 3 tỉ lệ (stride 8/16/32) với ảnh 640×640.

- Chọn YOLO26n (2,4 triệu tham số) thay YOLOv8n của thiết kế v1, vì cùng cỡ nhưng mới hơn hai thế hệ và có thêm đầu một-một cho phép suy luận không cần NMS.
- Khởi tạo từ trọng số COCO, ultralytics 8.4.173. Huấn luyện trên L40S dùng chung: giới hạn 15% bộ nhớ, batch cố định 16, đỉnh dùng thực tế 3,65 GiB.

- Phục vụ: xuất ONNX đầu thô (1×17×8.400) rồi chạy NMS theo lớp, IoU 0,7, trong worker. Ngưỡng điểm được chọn trên val và lưu cùng phiên bản mô hình, không nằm trong mã.
- Đánh giá bằng AP kiểu COCO (faster-coco-eval). AP vật nhỏ tính trên khung < 32^2 pixel. Khoảng tin cậy dùng bootstrap cụm có cặp.

5.3 Đếm (bài toán 3)

Đơn vị đánh giá là cặp (ảnh, lớp đếm được) có $c > 0$ hoặc $\hat{c} > 0$, để cặp vắng mặt không làm sai số nhỏ đi giả tạo.

```
\text{MAE} = \frac{1}{N} \sum |\hat{c} - c|, \qquad \text{MAE}_{rel} =
\frac{\sum |\hat{c} - c|}{\sum c}
```

Kèm tỷ lệ đúng tuyệt đối và đúng ±1. Ngưỡng τ chọn trên val ($\tau = 0{,}2$ cho cả 3 seed). Baseline là "trung vị theo lớp" được biết trước lớp có mặt, tức một baseline lạc quan. Khung group-of của Open Images (một khung bao cả đống) bị loại vì không cho biết số vật.

5.4 Độ tươi: cổ điển so với học sâu (bài toán 4)

Cả hai nhánh dùng chung một mặt nạ tiền cảnh GrabCut, để nhánh cổ điển không bị nền làm nhiễu (tỷ lệ tiền cảnh trung bình 0,247).

- **Cổ điển:** histogram HSV 18×8×8 bin; LBP đều (Ojala 2002) với (P, R) = (8, 1) và (16, 2); 6 thuộc tính GLCM (Haralick 1973) ở khoảng cách 1 và 3 theo 4 hướng; trung bình và độ lệch Lab*. Bộ phân loại là SVM RBF, C và γ chọn bằng CV lồng.
- **Học sâu:** MobileNetV3-Small (Howard và cộng sự 2019), khởi tạo ImageNet, 10 epoch AdamW. Mô hình có 1,5 triệu tham số, ONNX 6,1 MB.
- **Chia tập:** StratifiedGroupKFold 5 fold × 3 lần lặp, nhóm theo lô chụp. Sau khi phát hiện rò rỉ, nhóm theo cụm cận trùng pHash, kể cả bản bất biến xoay/lật.
- **Chỉ số:** macro-F1, κ trọng số bậc hai (QWK, phạt nhầm xa nặng hơn) và MAE theo bậc. Hai nhánh được so bằng bootstrap cụm theo nhóm, 2.000 lần.

5.5 Thu và gán nhãn (bài toán 5)

- **Chia tập theo hộ:** đơn vị chia và đơn vị bootstrap là hộ, không phải ảnh, vì ảnh cùng tủ tương quan mạnh.
- **Vòng gán thử:** hai người gán từ đầu, không dùng nháp. Ghép khung bằng thuật toán Hungarian ở IoU ⩾ 0,5. Báo F1 giữa hai người, tỷ lệ khung không ghép được, trung vị IoU và κ Cohen (1960) trên tên lớp.
- **Ngưỡng đồng thuận:** κ ⩾ 0,81, mức "gần như hoàn toàn" theo Landis & Koch (1977).
- **Nháp tự động:** nháp từ Grounding DINO (Liu và cộng sự 2024) chỉ dùng cho train.

- **Học chủ động:** ảnh người dùng sửa chip (nếu họ đồng ý góp ảnh) vào hàng đợi gán nhãn. Việc sửa chip chỉ là tín hiệu chọn ảnh, không phải nhãn khung.

5.6 Baseline Gemini (bài toán 6)

Công cụ đã viết và có kiểm thử trên phản hồi giả lập, nhưng chưa gọi API vì chưa có khoá. Thiết kế đánh giá:

- **Prompt:** danh mục đóng 22 lớp qua structured output, nhiệt độ 0, ghim model ID và ngày chạy, 3 lần chạy.
- **Ba cấp so sánh:** P/R/F1 khung ở IoU 0,5 và 0,3, MAE đếm, P/R/F1 danh sách. Không dùng mAP vì Gemini không trả điểm tin cậy.
- **Thêm:** độ trễ và chi phí.
- **Chỉ dùng ảnh của nhóm** đã có đồng ý của chủ bếp, gói trả phí.

6. Kết quả đã đo

Trên ảnh công khai, bộ phát hiện đạt AP 0,27 và chạy dưới 30 ms trên CPU. Tiền xử lý chưa cho khác biệt rõ, bộ đếm gần ngang baseline, còn bộ độ tươi học sâu thắng cổ điển ở mọi cách chia tập. Số liệu đọc từ `data/processed/cv/` (YOLO26n, 640 px, tập test 2.035 ảnh, 7.946 khung).

6.1 Tiền xử lý (60 epoch, dừng sớm patience 15)

Nhánh	Số seed	mAP50 test	mAP50-95 test
Ảnh gốc	3	0,414 ± 0,009	0,268 ± 0,005
Gray-world	3	0,418 ± 0,005	0,275 ± 0,002
Tăng cường đổi nguồn sáng	2	0,420 ± 0,010	0,275 ± 0,006

Gray-world và tăng cường hơn ảnh gốc khoảng 0,7 điểm mAP50-95, nằm trong biên tương đương ±1,5 điểm đặt trước. Nên kết luận đúng là "chưa thấy khác biệt đáng kể", không phải "có lợi". Điều này khớp với Wang và cộng sự (2023): tăng cường ảnh thường không giúp bộ phát hiện sâu. Hai nhánh CLAHE và gray-world + CLAHE ở 60 epoch, cùng seed thứ 3 của nhánh tăng cường, chưa chạy xong. CLAHE mới có lưới chọn tham số trên val (20 epoch, clip 1,0 × 16 tốt nhất: AP val 0,344). Trên ảnh công khai, nguồn sáng đồng đều hơn tủ lạnh nhiều, nên thí nghiệm này phải làm lại khi có ảnh tủ lạnh.

6.2 NMS so với đầu một-một không NMS (ảnh gốc, trung bình 3 seed)

Chế độ	AP@[.5:.95]	AP50	AP vật nhỏ	AR@100
Đầu một-nhiều + NMS	0,268	0,413	0,030	0,557
Đầu một-một, không NMS	0,256	0,395	0,029	0,565

NMS cho AP cao hơn 1,2 điểm ở cả 3 seed, nên bản triển khai dùng NMS. Chế độ không NMS có recall nhỉnh hơn nhưng độ chính xác thấp hơn. Vật nhỏ là điểm yếu nhất: AP chỉ 0,03 trên 376 khung nhỏ của test. Các lớp yếu nhất (AP50 test, mô hình đầu tiên) là bí đao 0,12, mướp đắng 0,17 và đậu que 0,25.

6.3 Đếm (lớp đếm được, $\tau = 0{,}2$ chọn trên val, 3 seed)

Phương pháp, trên cặp có lớp trong nhãn	MAE (vật)	MAE tương đối	Đúng tuyệt đối	Đúng ±1
YOLO26n + NMS	1,67	0,51	0,38	0,68
Trung vị theo lớp (baseline lạc quan)	1,80	0,55	0,29	0,69

Bộ phát hiện đếm đúng tuyệt đối nhiều hơn baseline (38% so với 29%), nhưng sai số trung bình chỉ giảm 0,13 vật và tỷ lệ đúng ±1 ngang nhau. Nguyên nhân chính là cà chua và trứng xếp chồng, nhiều vật nhỏ. Khi tính trên mọi cặp có $c > 0$ hoặc $\hat{c} > 0$, MAE là 1,72 và MAE tương đối 0,67. Chế độ không NMS cho số gần như bằng.

6.4 Độ tươi (9.182 ảnh, 5 fold × 3 lần lặp)

Cách nhóm khi chia tập	Số nhóm	SVM macro-F1	MobileNetV3 macro-F1	MobileNetV3 QWK
Theo lô chụp	4.318	0,819	0,857	0,921
+ gộp cận trùng pHash ⩽ 4	3.326	0,797	0,855	0,914
+ gộp cả bản xoay/lật	2.366	0,766	0,828	0,898

- **Rò rỉ được xác nhận:** 34,2% ảnh Local Spinach có ảnh cận trùng nằm ở fold khác, trong khi AgriFreshNET chỉ 4,7%. Chia nghiêm hơn làm macro-F1 giảm 5,3 điểm với SVM và 2,9 điểm với MobileNetV3. Dòng cuối mới là số đáng tin.

- **Học sâu thắng ở mọi cách chia.** Theo lô: +0,033 macro-F1, khoảng tin cậy 95% 0,012–0,054, bootstrap cụm.
- **Mức giữa "dùng sớm" yếu nhất** với cả hai nhánh, đúng như dự đoán khi lớp này chỉ có 1.643 ảnh.

6.5 Độ trễ và triển khai

Phép đo	p50	p95
YOLO26n ONNX, 2 luồng CPU, kể cả letterbox và hậu xử lý	29,1 ms	30,4 ms
MobileNetV3 độ tươi ONNX, 2 luồng	1,2 ms	1,4 ms
Quét thật qua `safework.ctslab.net`, phía server, 1 người (40 lượt)	64 ms	105 ms
Quét thật, 5 người đồng thời (300 lượt)	72 ms	178 ms

Mọi phép đo chạy trên máy chủ lab dùng chung (Xeon Gold 6542Y, worker giới hạn 2 CPU / 4 GB), chưa phải VPS đích. Ảnh test là 640–1.024 px, không phải 1.280 px. Mô hình độ tươi đã xuất ONNX và khớp với PyTorch (sai khác xác suất $\leq 2{,}6 \times 10^{-7}$), nhưng chưa được bật trên bản live.

7. Vấn đề tồn tại và hướng giải quyết

Vấn đề gốc là thiếu dữ liệu tủ lạnh Việt. Phần lớn các việc còn lại chờ nó, nên đây là ưu tiên số một. Bảng xếp theo ưu tiên: P1 chặn kết quả báo cáo môn, P2 làm sai kết quả dùng thật, P3 là cải tiến.

Ưu tiên	Vấn đề	Nguyên nhân	Hướng xử lý
P1	Không có tập test tủ lạnh thật; mọi số đo không dự báo được chất lượng khi dùng	Chưa thu ảnh; ảnh công khai chụp ở studio, chợ, sạp rau	Thu ≥ 12–15 hộ × 2–3 phiên, đóng băng ≥ 4 hộ làm test trước khi huấn luyện lại; bootstrap cụm hai tầng (hộ rồi ảnh)

Ưu tiên	Vấn đề	Nguyên nhân	Hướng xử lý
P1	9/22 lớp (thịt lợn, thịt bò, thịt gà, đậu phụ, su su, mướp, rau cải, rau muống, giá đỗ) không nhận được	Không có bộ công khai tải được không cần khoá	Chụp riêng, kể cả ảnh "đồ vừa mua" trên bàn; thêm bộ Roboflow CC BY khi có khoá API và đã kiểm nguồn ảnh; dùng nhãn cha ("rau cải", "thịt đóng gói") khi mắt thường cũng khó tách
P1	Nhãn độ tươi không phải nhãn thị giác, chỉ 3 mức, chưa hiệu chỉnh	Mượn nhãn theo hạn dùng của bộ dữ liệu khác	Hai người chấm 4 mức có ảnh mẫu, mù ngày chụp, đo κ trọng số ≥ 0,81; hiệu chỉnh xác suất bằng temperature scaling (Guo và cộng sự 2017) trên val rồi mới bật u_img
P1	Baseline Gemini chưa chạy, nên chưa trả lời được câu "mô hình tự huấn luyện có đáng không"	Chưa có khoá API trả phí	Cấp khoá, chạy công cụ có sẵn trên cùng tập test tủ lạnh; so P/R/F1 khung, MAE đếm, độ trễ, chi phí bằng bootstrap cặp theo ảnh
P2	Vật nhỏ gần như bị bỏ qua (AP nhỏ 0,03)	640 px làm ớt, tỏi, chanh còn vài chục pixel	So imgsz 960 với 640 về AP vật nhỏ và độ trễ; hoặc cắt ảnh thành ô chồng lấn kiểu SAHI (Akyon và cộng sự 2022) cho ngăn đầy
P2	Đếm vật xếp chồng gần ngang baseline (MAE 1,67 so với 1,80)	Vật che nhau; NMS IoU 0,7 gộp hai quả sát nhau	Chọn ngưỡng IoU NMS theo lớp trên val; Soft-NMS (Bodla và cộng sự 2017); hiển thị số đếm dạng khoảng và để người dùng sửa; đo thêm sai số do che khuất trên một phần test
P2	Gray-world sai khi khung hình toàn rau xanh	Giả thuyết trung bình cảnh là xám bị phá	Đánh giá riêng bằng thẻ xám (sai số góc); so gray-world, shades-of-gray, gray-edge (van de Weijer và cộng sự 2007); giữ kẹp hệ số [1/2; 2]

Ưu tiên	Vấn đề	Nguyên nhân	Hướng xử lý
P2	Chưa đo độ trễ đầu–cuối trên điện thoại và VPS đích	Mới đo trên máy lab, ảnh ≤ 1.024 px	Đo với ảnh 1.280 px thật trong container `--cpus=2 --memory=4g`; ghi mốc thời gian phía app qua `/events`
P3	Giấy phép AGPL-3.0 của ultralytics ràng buộc mã nguồn khi thương mại hoá	AGPL phủ cả mã huấn luyện và mô hình sinh ra	Với đồ án: công bố mã theo AGPL; nếu thương mại hoá: đổi sang bộ phát hiện Apache-2.0 (D-FINE, RT-DETRv2, RF-DETR) và so lại
P3	Chưa so với YOLO11n và ảnh 960 px	Thí nghiệm GPU bị dừng khi ổ đĩa và GPU dùng chung cạn	Chạy tiếp hàng đợi đã có (≤ 3 job, điều kiện GPU trống ≥ 6 GB)
P3	Vòng phản hồi từ người dùng chưa thành dữ liệu huấn luyện	Chip sửa không có khung	Học chủ động: ảnh có sửa hoặc độ tin cậy thấp vào hàng đợi gán nhãn Label Studio; cổng triển khai không-kém với biên đặt trước trên tập cổng riêng

8. Kế hoạch thí nghiệm và đánh giá tiếp theo

Mỗi câu hỏi có một chỉ số chính, một mốc so và một kiểm định đặt trước. Tập test tủ lạnh chỉ mở một lần cho số liệu báo cáo; mọi lựa chọn tham số làm trên val hoặc GroupKFold theo hộ.

Câu hỏi	Chỉ số chính	So với	Kiểm định
Tiền xử lý có giúp không?	AP@[.5:.95], 5 nhánh × 3 seed	Ảnh gốc	Chênh lệch có cặp, bootstrap cụm theo hộ; biên tương đương ±1,5 điểm
Tự huấn luyện có đáng không?	F1 khung IoU 0,5, MAE đếm, F1 danh sách, độ trễ, chi phí	Gemini (model ID và ngày ghim)	Bootstrap cặp theo ảnh, cụm theo hộ
Đếm đúng đến đâu?	MAE, MAE tương đối, đúng ±1	Trung vị theo lớp; đếm từ khung Gemini	Khoảng tin cậy bootstrap

Câu hỏi	Chỉ số chính	So với	Kiểm định
Cổ điển hay học sâu cho độ tươi?	Macro-F1, QWK, MAE bậc	HSV + LBP + GLCM + SVM	GroupKFold theo lô 5 × 3, bootstrap cụm; McNemar chính xác chỉ là phân tích phụ
Cân bằng trắng nào tốt nhất?	Sai số góc so với thẻ xám	Gray-world, shades-of-gray, gray-edge	Wilcoxon có cặp theo ảnh
Đủ nhanh trên VPS đích không?	p50 / p95 xử lý server và đầu-cuối	NFR-PERF-01 (p95 ⩽ 3 s)	⩾ 300 mẫu, 1 và 5 người đồng thời, khoảng tin cậy cho p95

Thứ tự làm đề xuất:

1. Vòng gán nhãn thử 100–150 ảnh, chốt danh mục lớp và hướng dẫn v2, rồi đóng băng tập test theo hộ.
2. Huấn luyện lại trên ảnh công khai cộng ảnh nhóm, lặp lại ablation tiền xử lý trên dữ liệu tủ lạnh.
3. Chạy baseline Gemini trên cùng tập test.
4. Thu lô độ tươi với thẻ xám, chấm nhãn 4 mức, hiệu chỉnh và bật u_img trên bản live.
5. Đo độ trễ trên VPS đích và điện thoại.

Một rủi ro cần biết: nếu Gemini thắng rõ ở phát hiện, lý do giữ mô hình tự huấn luyện sẽ là độ trễ (khoảng 30 ms trên CPU), chi phí 0 mỗi lần quét, chạy không cần mạng, và ảnh tủ lạnh không rời khỏi máy chủ trong nước. Các điểm này cần được đo, không chỉ nêu.

9. Tài liệu tham khảo

Các mục [1]–[10] và [17]–[22] đã được kiểm trên Crossref / trang gốc trong đợt rà soát tài liệu ngày 17/10/2026 (`docs/research/raw/`). Các mục còn lại ghi theo thông tin xuất bản chuẩn, chưa mở lại trong đợt này.

Phương pháp

1. Redmon J, Divvala S, Girshick R, Farhadi A. You only look once: Unified, real-time object detection. CVPR. 2016:779–788.
2. Jocher G, Qiu J. Ultralytics YOLO (YOLO11, YOLO26), phiên bản 8.4.173. Giấy phép AGPL-3.0. docs.ultralytics.com
3. Lin TY, Maire M, Belongie S, et al. Microsoft COCO: Common objects in context. ECCV. 2014:740–755. doi:10.1007/978-3-319-10602-1_48. Chỉ số AP@[.5:.95]: cocodataset.org/#detection-eval

4. Liu S, Zeng Z, Ren T, et al. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. ECCV. 2024:38–55. doi:10.1007/978-3-031-72970-6_3
5. Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3. ICCV. 2019:1314–1324.
6. Ojala T, Pietikäinen M, Mäenpää T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. IEEE TPAMI. 2002;24(7):971–987.
7. Haralick RM, Shanmugam K, Dinstein I. Textural features for image classification. IEEE Trans. SMC. 1973;SMC-3(6):610–621.
8. Cortes C, Vapnik V. Support-vector networks. Machine Learning. 1995;20(3):273–297.
9. Buchsbaum G. A spatial processor model for object colour perception. Journal of the Franklin Institute. 1980;310(1):1–26.
10. Zuiderveld K. Contrast limited adaptive histogram equalization. In: Graphics Gems IV. Academic Press; 1994:474–485.
11. Finlayson GD, Trezzi E. Shades of gray and colour constancy. Color and Imaging Conference. 2004:37–41.
12. van de Weijer J, Gevers T, Gijsenij A. Edge-based color constancy. IEEE Transactions on Image Processing. 2007;16(9):2207–2214.
13. Afifi M, Brown MS. What else can fool deep learning? Addressing color constancy errors on deep neural network performance. ICCV. 2019. arXiv:1912.06960
14. Bodla N, Singh B, Chellappa R, Davis LS. Soft-NMS — Improving object detection with one line of code. ICCV. 2017:5561–5569.
15. Akyon FC, Altinuc SO, Temizel A. Slicing aided hyper inference and fine-tuning for small object detection. ICIP. 2022.
16. Guo C, Pleiss G, Sun Y, Weinberger KQ. On calibration of modern neural networks. ICML. 2017:1321–1330.
17. Cohen J. A coefficient of agreement for nominal scales. Educational and Psychological Measurement. 1960;20(1):37–46. doi:10.1177/001316446002000104
18. Landis JR, Koch GG. The measurement of observer agreement for categorical data. Biometrics. 1977;33(1):159–174. doi:10.2307/2529310
19. McNemar Q. Note on the sampling error of the difference between correlated proportions or percentages. Psychometrika. 1947;12(2):153–157. doi:10.1007/BF02295996
20. Dietterich TG. Approximate statistical tests for comparing supervised classification learning algorithms. Neural Computation. 1998;10(7):1895–1923. doi:10.1162/089976698300017197
21. Efron B, Tibshirani RJ. An Introduction to the Bootstrap. Chapman & Hall; 1993.

22. Wang và cộng sự. Nghiên cứu ảnh hưởng của tăng cường ảnh dưới nước lên bộ phát hiện (18 phương pháp tăng cường × 7 bộ phát hiện; ảnh gốc cho AP cao nhất). 2023. arXiv:2311.18814

Đánh giá chất lượng nông sản bằng thị giác máy

23. Brosnan T, Sun DW. Improving quality inspection of food products by computer vision — a review. Journal of Food Engineering. 2004;61(1):3–16.
24. Bhargava A, Bansal A. Fruits and vegetables quality evaluation using computer vision: A review. Journal of King Saud University — Computer and Information Sciences. 2021;33(3):243–257.
25. Koyama và cộng sự. Ước lượng độ tươi rau bina từ ảnh chụp hằng ngày trong 12 ngày ở 10 °C, nhãn cảm quan 4 mức từ 12 người đánh giá, đặc trưng màu + ORB + SVM RBF. PLOS ONE. 2021. doi:10.1371/journal.pone.0248769
26. Abeer MH, Lamia MN, Nafsi JF, Chowdhury F, Anol MS, Ahamed MS. Local vegetable freshness classification based on chronological monitoring using transfer learning approach. ICCIDS 2023, IFIP AICT 673. 2023:50–66. doi:10.1007/978-3-031-38296-3_5

Dữ liệu

27. Kuznetsova A, et al. Open Images V7, tập boxable. storage.googleapis.com/openimages
28. Jahan et al. Vegetable Object Detection Dataset from Bangladesh. Mendeley Data V3; 2025. doi:10.17632/gnc4s3z2mf.3
29. Risdin F, Salauddin H, Tufa TA, Hossain MJ. AgriFreshNET Freshness and Shelf-Life Image Dataset. Mendeley Data V1; 2026. doi:10.17632/42m5tb7yv9.1
30. Hasan et al. Local Spinach Leaf Dataset. Mendeley Data V3; 2024. doi:10.17632/skf6w2s2h2.3

API và công cụ

31. Google. Gemini API — Image understanding (phát hiện đối tượng, `box_2d` chuẩn hoá 0–1000). ai.google.dev
32. ONNX Runtime 1.31.0. onnxruntime.ai

Tài liệu nội bộ của dự án (repo `~/NamBuw/Tastoria`): thiết kế v2 `docs/superpowers/specs/2026-10-17-tastoria-thiet-ke-v2.md`; báo cáo môn `docs/reports/xu-ly-anh/bao-cao-xu-ly-anh.md`; kết quả máy đọc được `data/processed/cv/`; nghiên cứu dữ liệu và mô hình `docs/research/raw/01-xu-ly-anh-du-lieu-mo-hinh.md`.